Vysoké učení technické v Brně
Fakulta informačních technologií

SUI — Umělá inteligence a strojové učení

# Umělá inteligence pro Válku kostek

**Josef Kolář** (xkolar71)
Dominik Harmim (xharmi00)
Petr Kapoun (xkapou04)
Jindřich Šesták (xsesta05)

17. prosince 2020

# Obsah

# 1 Úvod

Cílem projektu bylo vytvořit *umělou inteligenci (AI)* pro hru **Válka kostek**. Umělá inteligence musí *prohledávat stavový prostor* hry a musí využívat *strojové učení*. Projekt je postaven na bakalářské práci [3][1].

Dokumentace je dále strukturována následovně. Kapitola 2 pojednává o základní implementaci umělé inteligence založené na prohledávání stavového prostoru hry. Kapitola 3 popisuje rozšíření implementace o prvky strojového učení. Vyhodnocení výsledné umělé inteligence a srovnání použitých přístupů je popsáno v kapitole 4. Kapitola 5 vysvětluje obsah odevzdávaného archivu. Konečně kapitola 6 shrnuje výsledky tohoto projektu.

# 2 Implementace umělé inteligence prohledáváním stavového prostoru

Po analýze prostředí a implementace hry bylo zjištěno, že prostředí je *plně pozorovatelné* a *stochastické*. Na základě těchto vlastností bylo nejdříve uvažováno o implementaci umělé inteligence jako *agenta* (agent reprezentuje jednoho hráče), který bude implementovat *prohledávání stavového prostoru* algoritmem $ExpectiMiniMax$ popsaným v původní bakalářské práci [3]. Tento algoritmus vychází z algoritmu $MiniMax$. Je však rozšířen o *nedeterministické* akce, proto je vhodný pro toto stochastické prostředí.

Algoritmus $MiniMax$ i $ExpectiMiniMax$ je však ve své standardní variantě definován pouze pro hru dvou hráčů. V tomto projektu je nutné uvažovat hru čtyřech (a obecně $n$) hráčů. Existuje zobecnění těchto algoritmů pro hru $n$ hráčů. Jedná se o tzv. $Max^n$ algoritmus, který lze opět rozšířit o nedeterminismus. Dále bude hovořeno pouze o $Max^n$ algoritmu, ale ve výsledné implementaci tohoto projektu byl patřičně rozšířen i o nedeterministické akce. Algoritmus $Max^n$ byl poprvé představen v článku *An Algorithmic Solution of N-Person Games* [1], kde je podrobně popsán spolu s problematikou her pro více hráčů. Článek *Comparison of Algorithms for Multi-player Games* [2] pak srovnává algoritmus $Max^n$ s alternativními algoritmy pro hry více hráčů.

## 2.1 Algoritmus $Max^n$

Algoritmus $Max^n$ je přesně definován ve výše uvedených článcích [1, 2], proto bude v této kapitole už jen neformálně popsán a znázorněn.

V klasickém algoritmu $MiniMax$ se střídají tahy dvou hráčů. Hráč na tahu — $MAX$ — se snaží vybírat tahy vedoucí do stavů s maximálním ohodnocením, tj. snaží se maximalizovat svoji *objektivní funkci*. Protihráč — $MIN$ — se naopak snaží minimalizovat objektivní funkci hráče $MAX$. Tyto dvě hodnoty lze reprezentovat jednou hodnotu vytvořením jejich sumy. Je také možné dívat se na tento problém tak, že každý z hráčů se snažím maximalizovat svoji vlastní objektivní funkci. Potom by se dalo při prohledávání stavového prostoru tohle reprezentovat jako dvojice maximálních hodnot objektivní funkce pro každého z hráčů.

Algoritmus $Max^n$ potom funguje stejně jako $MiniMax$, kde se ale při prohledávání uvažuje $n$-tice, kde $n$ je počet hráčů. Každý prvek této $n$-tice reprezentuje maximalizovanou hodnotu objektivní funkce daného hráče a každý z hráčů se snaží svoji objektivní funkci při svém tahu maximalizovat. Algoritmus je ilustrován na obrázku 1. Uvažuje se hra pro 3 hráče — A, B, C. Tito hráči se v uvedeném pořadí střídají při hraní svých tahů. Každý z hráčů může provést dva možné tahy. Po třech tazích hra skončí (obecně by po tahu hráče C hrál opět hráč A, ale zde jsou tahy hráče C uvažovány jako koncové, po nichž hra končí). Stav hry je tady popsán trojicí — $(obj(\mathrm{A}), obj(\mathrm{B}), obj(\mathrm{C}))$ — kde $obj(\mathrm{X})$ je hodnota objektivní funkce hráče X. Na obrázku je vidět expandovaný graf hry pro dané hráče. Listové uzly jsou

[1] Projekt je konkrétně založen na upravené verzi z původní bakalářské práce: https://github.com/ibenes/dicewars.

ohodnoceny objektivní funkcí a nelistové uzly jsou ohodnoceny podle maximalizace objektivní funkce aktuálního hráče na tahu. Je zřejmé, že hráč A učiní tah „vpravo“, protože stav, do kterého tento tah vede, je ohodnocen pro něho nejlepší objektivní funkcí — $(1, 1, 1)$. Cesta do koncového stavu s tímto ohodnocením je vyznačena červenými hranami.

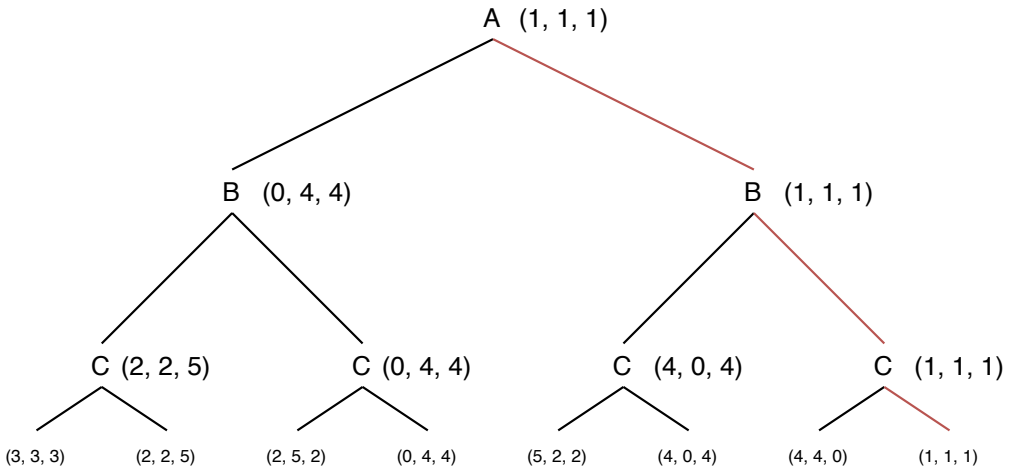


Obrázek 1: Příklad *prohledávání stavového prostoru* hry pro 3 hráče algoritmem $Max^n$

## 2.2 Konkrétní implementace a použití algoritmu $Max^n$

Tato kapitola popisuje výslednou implementaci umělé inteligence prohledáváním stavového prostoru algoritmem $Max^n$ pro tento projekt. Dále popisuje rozšíření tohoto algoritmu o nedeterministické akce a konkrétní použití v projektu.

Implementace prohledávání stavového prostoru se nachází ve třídě `dicewars.ai.xkolar71.AI` (kromě implementace heuristické funkce pro ohodnocování stavů hry, která je implementována ve třídě `dicewars.ai.xkolar72_orig.AI`, vzhledem k tomu, že heuristická funkce byla nakonec nahrazena strojově učeným modelem, viz kapitola 3).

**Definice 2.1** ($maxN$)**.** Byla definována *rekursívní* funkce $maxN$, která implementuje algoritmus $Max^n$ pro účely tohoto projektu. Funkce v každém tahu daného hráče zkoumá následující tahy všech ostatních hráčů v patřičném pořadí a vrací nejlepší spočítaný tah. Funkce konkrétně uvažuje $n$ iterací prohledávání tahů všech následujících hráčů. Parametr $n$ byl experimentálně zvolen na hodnotu 1, tj. uvažuje se nanejvýše jedenkrát sekvence tahů každého z následujících hráčů. Při vyšších hodnotách tohoto parametru už byly naměřeny horší výsledky, což je způsobené tím, že prostředí hry je *silně nedeterministické* a jen obtížně lze přesněji predikovat výsledky akcí dále do budoucnosti. Při zkoumání tahů hráče následujícího v pořadí se generuje $m$ útoků. Následně z každého útoku se generuje $m-1$ útoků, z každého z nich $m-2$ útoků atd. až do hloubky $l$. Parametry $m$ a $l$ byly experimentálně nastaveny na hodnotu 5, opět s ohledem na stochastické prostředí. Útoky, které se generují v daném tahu, jsou vybrány jako ty možné útoky s *největší pravděpodobností* na výhru funkcí *possibleTurns*, viz definice 2.2. Tímto byl algoritmus $Max^n$ rozšířen o nedeterminismus. Uvažované útoky jsou vždy simulovány na kopii aktuální konfigurace hry. Funkce $maxN$ potom v listových uzel (definovaných parametry $n$ a $l$) ohodnotí daný stav *heuristickou funkcí* $h$, viz definice 2.3. Konečně $maxN$ maximalizuje hodnotu funkce $h$ pro každého z hráčů a vrací tah do uzlu s nejlepším ohodnocením.

**Definice 2.2** (*possibleTurns*)**.** Tato funkce vrací všechny tahy, které je možné provést seřazené podle *pravděpodobnosti* $p$. Tahy, které je možné provést, jsou všechny možné útoky (tj. útoky z území, na nichž jsou alespoň 2 kostky a sousedí s územím protihráče), jejichž pravděpodobnost $p$ je větší než 0,4 (bylo zvoleno experimentálně) a nebo je počet kostek na útočícím území roven 8 (největší možný

počet kostek na území). Pravděpodobnost $p$ je spočtena následovně $p = P_{A\to D} \cdot P_D \cdot P_L$, kde $P_{A\to D}$ je pravděpodobnost úspěšného útoku z území $A$ na území $D$, $P_D$ je pravděpodobnost udržení území $D$ po úspěšném útoku při tazích následujících hráčů a $P_L$ je 2 (zvoleno experimentálně) v případě, že území $A$ leží v největším regionu daného hráče, tj. je proveden útok z největšího území hráče, v opačném případě je $P_L = 1$. Výpočty těchto pravděpodobností jsou blíže diskutovány v původní bakalářské práci [3].

**Definice 2.3** ($h$)**.** Hodnota této *heuristické funkce* udává ohodnocení stavu hry pro každého hráče ve smyslu maximalizace jeho *objektivní funkce*. Hodnota $h$ pro hráče $i$ je spočtena následovně $h(i) = D(i) + \sum_r^{R(i)} 5r + 50 \max(R(i))$, kde $D(i)$ je počet kostek hráče $i$, $R(i)$ jsou velikosti regionů hráče $i$ a číselné konstanty byly zvoleny experimentálně.

Na nejvyšší úrovni je tah hráče určen tak, že pokud je zbývající časové omezení tahu větší než $x$ sekund a zároveň je počet tahů v aktuální sérii tahů daného hráče menší než $y$, tak se nalezne nejlepší tah funkcí $maxN$. V opačném případě se vybere nejlepší možný útok s ohledem na pravděpodobnost výhry funkcí $possibleTurns$. Pokud žádný takový útok není možný, tah se ukončí. Parametry $x$ a $y$ byly experimentálně nastaveny na hodnoty 1,0 a 5.

# 3 Strojově učený model pro heuristickou funkci

Model substituuje *heuristickou funkci* a pro každého hráče vyhodnocuje v rámci aktuální konfigurace hry jeho šanci na výhru. Vstupem je tedy serializace aktuální konfigurace hry (stavu desky a stavu hráčů) do XX celých čísel a výstupem je vektor 4 hodnot v intervalu $< 0; 1 >$, který udává odhad modelu na výhru jednotlivých hráčů; 0 značí, že model si je jistý s nevýhrou hráče s konkrétním indexem (resp. jménem).

## 3.1 Serializace hry

Pro trénování modelu jsme navrhli serializaci hry do vektoru XX celých čísel, který odpovídá konkrétnímu stavu hry, tedy desky a hráčů na ní hrajících. Výsledný vektor má následující strukturu:

- matice sousednosti $M_s$ definovaná jako

$$M_s = \begin{bmatrix} s(1,1) & s(1,2) & s(1,3) & \dots & s(1,29) \\ \cdot & s(2,2) & s(2,3) & \dots & s(2,29) \\ \cdot & \cdot & s(3,3) & \dots & s(3,29) \\ \cdot & \cdot & \cdot & \dots & s(4,29) \\ \cdot & \cdot & \cdot & \cdot & \dots \\ \cdot & \cdot & \cdot & \cdot & s(29,29) \end{bmatrix}$$

  kdy funkce $s(x, y)$ je definovaná následovně

$$s(x,y) = \begin{cases} 1 & \text{jestliže území } x \text{ sousedí s územím } y \\ 0 & \text{jinak} \end{cases}$$

  a výsledný vektor sousednosti je poté získán jako konkatenace řádků $M_s$ z trojúhelníku nad diagonálou. Jeho celková délka je $\frac{30*(30-1)}{2} = 435$ prvků.

- vlastníci polí — tedy vektor o délce 30 s hodnotami, resp. názvy, jednotlivých vlastníků polí, opět 30 prvků
- počtů kostek — vektor udávající množství kostek pro každé pole na desce
- velikosti největších regionů — vektor o délce 4 s $max(R(i))$ pro každého hráče $i$

Serializovaná hra je tedy vektor celočíselných nezáporných čísel složený ze čtyř sektorů s celkovou délkou $435 + 30 + 30 + 4 = 499$ prvků.

Po každém ukončeném tahu hráče je uschována serializace hry. Po konci hry je ke všem serializacím přiložen index vítěze konkrétní posloupnosti tahů a tento datový balíček je binárně uložen na disk. Pro tento účel byla upravena metoda `run` třídy `Game`, která se nachází v modulu `dicewars.server.game`. Pro tuto serializaci se dále používají funkce z vytvořeného modulu `dicewars.ml`.

### 3.2 Trénování modelu neuronové sítě

*Všechny skripty zmíněné v této sekci se nachází v adresáři `ml-scripts`.*

Čtyřikrát původní AI s $Max^n$ algoritmem, souborový systém se soubory s jednotlivými konfiguracemi. Pro finální natrénování modelu bylo použito 201 291 různých konfigurací her s odpovídajícími indexy vítězů. Pro generování konfigurací byla hra spuštěna vytvořeným skriptem `dump-data-to-learn.py`.

Pomocí skriptu `transform-to-numpy.py` je tato datová sada ze souborů transformována na pole typu `numpy` o dimenzích $(N, 1{+}499)$ — $N$ značí celkový počet konfigurací a 1+499 je index vítěze a kompletní serializace hry. Takto zkonstruované pole je uloženo jako jeden samostatný soubor pro další zpracování.

Implementace dalšího zpracování datové sady je pak v souboru `shuffle-datasets.py`, který ji načte, náhodně zamíchá podle první dimenze (tedy pořadí různých konfigurací) a následně rozdělí na *trénovací*, *validační* a *testovací* data. To dělá v poměru 70 %, 20 % a zbylých 10 % pro testovací data. Takto rozdělená sada je následně uložena do třech samostatných souborů.

Trénovací a validační část datové sady je následně použita pro natrénování modelu (skript `train-model.py`) — tím je v tomto případě *lineární neuronová síť*. Její architektura byla zvolena experimentálně a celkově se skládá z pěti vrstev, z čehož první vrstva je čistě vstupní se vstupním vektorem o délce 499 (délka vychází ze způsobu serializace). Následuje plně propojená vrstva s 64 parametry a ReLU aktivací, jako třetí figuruje v síti `Dropout` vrstva pro prevenci přeučení s pravděpodobností vynulování vstupů $p = 0.25$ a model je zakončen dvěma plně propojenými vrstvami s 32, resp. 4 parametry. Čtvrtá vrstva používá opět aktivaci ReLU, výstupní poté `softmax`. Níže je přiložen programový výstup z `keras` popisu modelu.

```
_________________________________________________
Layer (type)          Output Shape        Param #
=================================================
input_1 (InputLayer)  [(None, 499)]       0
_________________________________________________
dense (Dense)         (None, 64)          32000
_________________________________________________
dropout (Dropout)     (None, 64)          0
_________________________________________________
dense_1 (Dense)       (None, 32)          2080
_________________________________________________
dense_2 (Dense)       (None, 4)           132
=================================================
Total params: 34,212
Trainable params: 34,212
Non-trainable params: 0
_________________________________________________
```

Nutno zmínit, že v případě předpokládaných výsledků pro každou konfiguraci dochází ke *kategorizaci* — transformaci celočíselného indexu vítěze na vektor o počtu hráčů s hodnotou 1 na místě indexu vítěze

a hodnotami 0 na ostatních pozicích — tedy platí, že pro vítěze s indexem $i$ je modelu předložen předpokládaný vektor $\begin{bmatrix} x_1 & x_2 & x_3 & x_4 \end{bmatrix}$ u kterého platí, že $x_i = 1$, a 0 jinak.

Pro samotné natrénování je použit algoritmus `Adam` pro optimalizátor s *learning rate* na hodnotě $0,01$. Jako *loss* pak trénování používá instanci `CategoricalCrossentropy` dodanou přímo knihovnou `keras`. Jako velikost trénovací i validační dávky jsme experimentálně stanovili hodnotu 32 a počet epoch jsme opět experimentálně nastavili na 15.

Pro ověření správnosti modelu jsme připravili skript `check-test-accuracy.py`, který určí přesnost odhadů nad částí datové sady určenou pro testování (tedy 10 % z původní sady). Natrénovaný model z testovací datové sady o velikosti 20 130 správně určil celkem 19 804 vzorků, což značí úspěšnost cca 98.3 %.

Pro ověření rychlosti vyhodnocení modelu pro vstupní data jsme připravili skript `profile-predict.py`, s pomocí kterého jsme za asistence `CProfile` profileru měřili rychlost vyhodnocení. Pro výše definovanou síť a testovací část datové sady bylo experimentálně změřeno první vyhodnocení cca 1,5 násobně delší, než ty následující (tedy 550 ms oproti 350 ms) — což je známý a popsaný problém modelů založených na Tensorflow[2].

### 3.3 Integrace modelu

Pro použití natrénovaného modelu v AI je upravena heuristická funkce, která nyní na základě předané konfigurace hry vyhodnocuje jednotlivé hráče, resp. jejich šanci na vítězství. Konkrétně se jedná o funkci `_heuristic(players: List[int], board: Board)`, která na základě předaného seznamu aktivních hráčů a instance desky provede nejprve serializaci (dle postupu popsaného výše), následně vyhodnotí konfiguraci v natrénovaném modelu a nazpět vrátí ohodnocení stavu hry pro jednotlivé hráče — konkrétní hodnota pro hráče odpovídá maximalizaci jeho *objektivní funkce*.

## 4 Vyhodnocení implementace umělé inteligence

Po prvotní implementaci algoritmu $Max^n$ pro účely umělé inteligence pro tuto hru jsme začali experimentovat s hraním soutěžních turnajů, kterých se účastnila i tato inteligence. Do turnajů jsme zapojovali umělé inteligence dle zadání výsledného soutěžního turnaje, tedy `dt.ste`, `dt.wpm_c`, `dt.sdc`, `xlogin00` a nakonec i `xkolar71`. Po prvotním odladění parametrů (popsaných v kapitole 2.2) na základě experimentů se turnajová úspěšnost pohybovala mezi 35 % a 60 % — viz výsledky turnajů zobrazených v 2.

S prvními výsledky po implementaci algoritmu $Max^n$ jsme vygenerovali serializace konfigurací her určené pro natrénování modelu, jak je popsáno v 3.2, a natrénovaný model následně integrovali do umělé inteligence, konkrétně do její heuristické funkce (jak popisuje 3.3). Nad takto upravenou umělou inteligencí jsme spustili další turnaje, z nichž naše umělá inteligence vycházela s úspěšností na úrovni umělé inteligence bez integrace modelu — na základě tohoto pozorování jsme iterativně vylepšovali trénování modelu (experimentální změny architektury sítě, konkrétní struktury serializovaných her či velikostí datových sad).

Tyto iterace změn vedly ve výsledku k úspěšnosti umělé inteligence s integrovaným modelem na úrovni stabilních 39 % až 43 % na turnajích s násobně vyššími počty her (nad 1000). Výsledky z některých turnajů jsou zobrazeny v 3 a nutné je poznamenat, že AI `xkolar71` s integrovaným modelem vycházela z těchto turnajů úspěšněji než verze AI `xkolar71_orig`, která je původní implementací bez integrovaného modelu.

[2] https://github.com/tensorflow/tensorflow/issues/39458

```
dt.sdc    34.38 % winrate [ 11 / 32 ] 37.5/24 34.4/32 33.3/24 37.5/24  29.2/24
xkolar71  34.38 % winrate [ 11 / 32 ] 41.7/24 25.0/24 33.3/24 37.5/24  34.4/32
dt.ste    25.00 % winrate [ 8  / 32 ] 29.2/24 25.0/24 25.0/32 20.8/24  25.0/24
dt.wpm_c  25.00 % winrate [ 8  / 32 ] 16.7/24 29.2/24 25.0/24 25.0/32  29.2/24
dt.rand   6.25  % winrate [ 2  / 32 ] 6.2/32  8.3/24  8.3/24  4.2/24   4.2/24
```

```
xkolar71  60.42 % winrate [ 29 / 48 ] 59.4/32 62.5/24 67.9/28 50.0/28  62.5/32  60.4/48
dt.ste    38.46 % winrate [ 20 / 52 ] 44.4/36 43.8/32 38.5/52 42.9/28  34.4/32  25.0/28
dt.wpm_c  30.36 % winrate [ 17 / 56 ] 29.5/44 30.6/36 25.0/28 30.4/56  40.6/32  25.0/28
dt.sdc    17.31 % winrate [ 9  / 52 ] 19.4/36 17.3/52 9.4/32  25.0/36  17.9/28  12.5/24
dt.rand   5.00  % winrate [ 3  / 60 ] 5.0/60  5.6/36  5.6/36  6.8/44   3.1/32   3.1/32
xlogin00  3.85  % winrate [ 2  / 52 ] 6.2/32  3.6/28  3.1/32  3.1/32   3.8/52   3.1/32
```

```
xkolar71  45.00 % winrate [ 27 / 60 ] 45.5/44 39.6/48 47.7/44  47.7/44  45.0/60
dt.ste    33.82 % winrate [ 23 / 68 ] 34.6/52 33.8/68 34.6/52  36.5/52  29.2/48
dt.wpm_c  18.75 % winrate [ 12 / 64 ] 20.8/48 17.3/52 18.8/64  18.8/48  18.2/44
dt.sdc    17.19 % winrate [ 11 / 64 ] 17.2/64 19.2/52 16.7/48  16.7/48  15.9/44
xlogin00  10.94 % winrate [ 7  / 64 ] 10.4/48 13.5/52 10.4/48  10.9/64  9.1/44
```

Obrázek 2: Výsledky soutěžních turnajů po prvotní implementaci umělé inteligence — tedy bez strojového učení.

```
xkolar71      39.43 % winrate [ 358 / 908 ] 40.7/452 41.1/440 35.9/468 40.1/444 42.8/444 39.4/908 36.3/476
dt.ste        37.66 % winrate [ 351 / 932 ] 42.1/468 40.3/476 37.7/932 35.6/464 40.2/448 33.1/468 34.7/472
xkolar71_orig 35.04 % winrate [ 321 / 916 ] 35.5/456 33.3/456 34.7/472 36.7/444 36.9/444 33.2/476 35.0/916
dt.wpm_c      24.67 % winrate [ 224 / 908 ] 28.5/452 23.7/452 19.0/464 24.7/908 31.6/468 22.3/444 22.7/444
dt.sdc        24.34 % winrate [ 223 / 916 ] 30.7/456 24.3/916 22.3/476 24.1/452 26.9/468 19.3/440 22.6/456
xlogin00      7.93  % winrate [ 72  / 908 ] 10.8/452 5.8/468  7.1/448  7.5/468  7.9/908  9.0/444  7.4/444
dt.rand       5.59  % winrate [ 51  / 912 ] 5.6/912  7.5/456  4.9/468  7.5/452  6.2/452  2.9/452  4.6/456
```

```
xkolar71      39.00 % winrate [ 443 / 1136 ] 44.6/572 37.1/568  34.1/580  41.4/568  40.7/560 39.0/1136 36.1/560
xkolar71_orig 35.87 % winrate [ 406 / 1132 ] 37.1/564 37.5/560  35.6/568  36.0/572  38.3/572 30.7/560  35.9/1132
dt.ste        34.67 % winrate [ 405 / 1168 ] 37.8/576 36.0/620  34.7/1168 35.2/576  38.4/584 29.5/580  31.0/568
dt.sdc        27.09 % winrate [ 311 / 1148 ] 32.6/564 27.1/1148 25.5/620  24.1/568  28.4/564 26.8/568  25.4/560
dt.wpm_c      25.00 % winrate [ 285 / 1140 ] 28.5/576 21.0/568  22.9/576  25.0/1140 31.6/560 22.0/568  24.1/572
xlogin00      7.48  % winrate [ 85  / 1136 ] 7.9/568  6.0/564   8.0/584   7.9/560   7.5/1136 8.2/560   6.8/572
dt.rand       5.70  % winrate [ 65  / 1140 ] 5.7/1140 7.1/564   4.5/576   5.2/576   7.6/568  4.7/572   5.1/564
```

```
xkolar71  43.56 % winrate [ 115 / 264 ] 45.0/160 42.5/160 37.2/156 44.9/156 48.1/160 43.6/264
dt.ste    41.29 % winrate [ 109 / 264 ] 45.6/160 37.8/156 41.3/264 45.0/160 39.4/160 38.5/156
dt.sdc    28.41 % winrate [ 75  / 264 ] 30.5/164 28.4/264 25.0/156 28.2/156 32.7/156 25.6/160
dt.wpm_c  23.51 % winrate [ 63  / 268 ] 26.2/168 25.0/156 21.9/160 23.5/268 26.8/164 17.3/156
xlogin00  8.58  % winrate [ 23  / 268 ] 11.0/164 9.0/156  10.6/160 4.9/164  8.6/268  7.5/160
dt.rand   5.51  % winrate [ 15  / 272 ] 5.5/272  5.5/164  3.8/160  6.5/168  6.1/164  5.6/160
```

Obrázek 3: Výsledky soutěžních turnajů po integraci naučeného modelu — tedy se strojovým učením. AI `xkolar71_orig` značí umělou inteligenci bez integrovaného modelu.

# 5 Obsah odevzdaného archivu

Odevzdaný archiv `xkolar71.zip` obsahuje následující soubory:

- `xkolar71/__init__.py` a `xkolar71/ai.py`: Balíček, který obsahuje implementaci umělé inteligence, která *používá strojové učení*. Viz kapitola 3.
- `xkolar71/model.h5`: Natrénovaný model založený na *neuronové síti*, který se používá pro modelování *heuristické funkce* pro ohodnocování stavů hry.
- `xkolar71/game.py`: Modul s implementací serializační funkce popsané v kapitole 3.1.
- `supplementary/dicewars/ai/xkolar71_orig.py`: Původní implementace umělé inteligence *bez strojového učení* popsaná v kapitole 2.
- `supplementary/dicewars/ai/xkolar71_2.py`, `supplementary/dicewars/ai/xkolar71_3.py`, `supplementary/dicewars/ai/xkolar71_4.py`:
  Další instance původní implementace umělé inteligence `supplementary/xkolar71_orig` vytvořené pro účely trénování modelu.
- `supplementary/dicewars/server/game.py`: Modifikovaný soubor s třídou, která řídí hru. Byla provedena úprava pro generování konfigurací hry za účelem trénování modelu. Viz kapitola 3.1.
- `supplementary/dicewars/ml/__init__.py` a `supplementary/dicewars/ml/game.py`: Balíček obsahující funkce sloužící k serializaci konfigurací hry. Viz kapitola 3.1.
- `supplementary/ml-scripts/dump-data-to-learn.py`: Skript pro generování konfigurací hry. Viz kapitola 3.2.
- `supplementary/ml-scripts/transform-to-numpy.py`: Skript pro převod vygenerovaných konfigurací hry na pole typu `numpy`. Viz kapitola 3.2.
- `supplementary/ml-scripts/shuffle-datasets.py`: Skript pro zamíchání konfigurací hry a jejich následné rozdělení na *trénovací*, *validační* a *testovací* datové sady. Viz kapitola 3.2.
- `supplementary/ml-scripts/train-model.py`: Skript pro vytvoření a trénování modelu založeném na neuronové síti. Viz kapitola 3.2.
- `supplementary/ml-scripts/check-test-accuracy.py`: Skript pro ověření správnosti modelu na testovacích datech. Viz kapitola 3.2.
- `supplementary/ml-scripts/profile-predict.py`: Skript pro ověření rychlosti predikce na testovacích datech. Viz kapitola 3.2.
- `requirements.txt`: Aktualizovaný seznam knihoven, na kterých je projekt závislý.
- `xkolar71.pdf`: Tato dokumentace k projektu.

# 6 Závěr

V rámci řešení tohoto projektu jsme po úvodním rozdělení práce nastudovali funkci algoritmu $Max^N$, abychom jej mohli následně implementovat a experimentálně nastavit jednotlivé parametry pro jeho běh – samotná funkce algoritmu je stručně popsána v kapitole 2 a to včetně popisu konkrétní implementace a jednotlivých parametrů. Po prvotní implementaci dosahovala umělá inteligence míry výher pohybujících nad úrovní 30 %, ve většině případů na prvním místě spouštěných turnajů.

Takto chovající se umělá inteligence byla následně použita (resp. čtyři identické její instance) pro vygenerování trénovací a validační datové sady, podle kterých byl poté natrénován model ze třívrstvé

neuronové sítě – tento proces včetně architektury sítě a trénovacího *workflow* je popsán v kapitole 3. Po integraci do původního algoritmu pomocí substituce heuristické funkce se míra výher nové umělé inteligence pohybovala nad 35 % a i nadále na prvních pozicích desítek soutěžních turnajů.

Závěrem této dokumentace je výčet souborů v odevzdaném archivu včetně popisu funkce jednotlivých skriptů pro možnou replikovatelnost.

## Reference


[1] Luckhardt, C. A. a Irani, K. B. An Algorithmic Solution of N-Person Games. In *Proceedings of the Fifth AAAI National Conference on Artificial Intelligence, Lecture Notes in Computer Science*. Philadelphia, Pennsylvania: AAAI Press, srpen 1986. S. 158—162. AAAI'86, sv. 2883. Dostupné na: <`https://www.aaai.org/Papers/AAAI/1986/AAAI86-025.pdf`>.

[2] Sturtevant, N. A Comparison of Algorithms for Multi-player Games. In Schaeffer, J., Müller, M. a Björnsson, Y. (ed.). *Computers and Games*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003. S. 108–122. ISBN 978-3-540-20545-6.

[3] Tureček, D. *Umělá inteligence pro deskovou hru*. Brno: Vysoké učení technické v Brně, Fakulta informačních technologií, 2018. Bakalářská práce. Ústav počítačové grafiky a multimédií.Vedoucí práce Ing. Karel Beneš. Dostupné na: <`https://www.fit.vut.cz/study/thesis/20290`>.